

05506015 Computer Ethics and Professional Issues · Term Project: Ethics in AI · ภาคเรียน 1/2569

AI Essay & Quiz Grader

ผู้ช่วยตรวจเรียงความและข้อสอบปรนัยด้วย AI พร้อมกลไกด้านจริยธรรมในตัวแอป

กลุ่ม Dario Amodei · จำนวนสมาชิก 6 คน

02 แอปพลิเคชันใช้ AI ทำอะไร

📝 ตรวจเรียงความ (Essay Grading)

วางเรียงความ → เลือก Rubric (ทั่วไป / เชิงโต้แย้ง / Pitch Deck) → AI ให้คะแนน **แยกรายเกณฑ์** พร้อมคอมเมนต์และ Feedback รายบุคคล

🧾 ตรวจข้อสอบปรนัย (Quiz Grading)

วางโจทย์ MCQ + คำตอบนักเรียน → AI **วิเคราะห์และสร้างเฉลย**พร้อมคำอธิบายรายข้อ → ระบบเทียบคำตอบและคำนวณคะแนน

🤖 โมเดลที่ใช้

Qwen 3.8 Max ผ่าน OpenAI-compatible API · เรียกผ่าน local proxy (Python) — API key ไม่ผ่านเบราว์เซอร์

✨ กลไกจริยธรรมที่ฝังในตัวแอป (ไม่ใช่แค่สไลด์)

- **Transparency panel** — แสดง prompt จริงที่ส่งให้ AI ทุกครั้ง
- **Anti-Hallucination** — ทุกคะแนนต้องแนบข้อความยกตรง (quote) จากตัวงาน
- **Consistency Check** — ตรวจงานเดิม 3 รอบ แสดงส่วนต่างคะแนน
- **Teacher Override + Audit Log** — มนุษย์แก้คะแนนได้ ต้องระบุเหตุผล ระบบบันทึกทุกครั้ง
- **Demo Mode ติดป้ายชัดเจน** — ผลลัพธ์จำลองไม่แอบอ้างเป็น AI จริง

▶ การสาธิตสด

รัน `python3 serve.py` → เปิด localhost:8000 → วางเรียงความตัวอย่าง → กดตรวจ → ดูคะแนนรายเกณฑ์ + evidence → กด Consistency Check ให้ดูคะแนนแกว่งจริง → แก้คะแนนด้วย Teacher Override → เปิด Audit Log

03 ประเด็นจริยธรรม AI ที่พบในแอปของเรา (วิเคราะห์เชิงลึก — ไม่ใช่แค่ระบุหัวข้อ)

⚖️ Bias / Fairness

โมเดลภาษาฝึกจากข้อมูลภาษาอังกฤษ/ไทยกลางเป็นหลัก → **ลำเอียงต่อสำนวนของนักเรียนที่ไม่ใช่เจ้าของภาษา** หรือใช้ภาษาท้องถิ่น งานที่ "เขียนสวยตามขนบ" อาจได้คะแนนสูงกว่างานที่เนื้อหาลึกแต่ภาษาง่าย — **ให้รางวัลกับสไตล์ ไม่ใช่สาระ**

🔒 Privacy (PDPA)

เรียงความ/ข้อสอบอาจมีข้อมูลส่วนบุคคลของนักเรียน (ข้อมูลผู้เยาว์ = **ข้อมูลอ่อนไหวตามกฎหมาย**) การส่งไป API ภายนอก = เปิดเผยข้อมูลให้ผู้ให้บริการโดยผู้เรียนไม่เคยยินยอม

🎭 Hallucination / Accuracy

ผลทดสอบจริงตอนพัฒนา: AI เคย**อ้างว่าพบคำสะกดผิดจำนวนมากในงานที่สะกดถูก** และให้คะแนนไวยากรณ์ต่ำโดยไม่มีหลักฐาน — ถ้าครูไม่ตรวจ นักเรียนถูกตัดคะแนนฟรี

👷 Accountability

ถ้า AI ให้คะแนนผิดจนนักเรียนเสียสิทธิ์ — ใครรับผิดชอบ? ครูที่กดปุ่ม? ผู้พัฒนาแอป? หรือผู้ให้บริการโมเดล? **ปัจจุบันไม่มีกฎหมายระบุชัด** → ถ้าไม่มี audit trail จะโยนความผิดกันไปมา

🔍 Transparency

คะแนนเป็น black box — นักเรียนไม่รู้ว่าถูกหักคะแนนเพราะอะไร **อุทธรณ์ไม่ได้** ถ้ามองไม่เห็นเกณฑ์และเหตุผล

🔁 Consistency & Over-reliance

ทดลองจริง: งานเดิม ตรวจ 3 รอบ คะแนนรวม **34 → 34 → 30 (แกว่ง 4 คะแนนเต็ม)** — ไม่ยุติธรรมต่อนักเรียนคนเดียวกัน และเมื่อระบบแกว่ง ครูอาจยิ่งพึ่ง AI เพราะ "ขี้เกียจตรวจเอง" แทนที่จะทบทวน

04 แนวทางแก้ไข/ป้องกัน ถ้าเราพัฒนาแอปนี้จริง

ประเด็น	แนวทางแก้ไข	ตัวอย่างรูปธรรม
Bias / Fairness	ทดสอบอคติด้วยชุดข้อมูลหลากหลายก่อนปล่อยใช้งาน (bias audit) + ระบุใน prompt ห้ามตัดสินจากสไตล์ภาษา + ให้คะแนนแยก "เนื้อหา" ออกจาก "ภาษา" เสมอ	ตรวจ essay เดียวกันที่เขียนโดยเจ้าของภาษา/ไม่ใช่เจ้าของภาษา เทียบคะแนน — ถ้าต่างอย่างมีนัยสำคัญ ต้องจูน rubric ก่อนเปิดใช้
Hallucination	บังคับ evidence-based grading: ทุกคะแนนต้อง quote ข้อความจริงจากงาน + ระบบตรวจกลับอัตโนมัติว่า quote มีอยู่จริงในต้นฉบับ	ทำแล้วในแอป — ถ้า evidence ไม่พบในข้อความต้นฉบับ ระบบขึ้นธง ⚠ ให้ครูตรวจสอบ
Transparency	เปิดเผย rubric + เหตุผลรายเกณฑ์ให้ผู้เรียนดูได้ทุกเมื่อ + มีช่องทางอุทธรณ์	ทำแล้วในแอป — Transparency panel แสดง prompt จริง + คะแนนนักเรียนกดดูเหตุผลรายข้อได้
Privacy / PDPA	ไม่เก็บงานนักเรียนบนเซิร์ฟเวอร์ (stateless) + key อยู่ฝั่ง proxy + anonymize ก่อนส่ง + ขอความยินยอมชัดเจน	ทำแล้วในแอป — ข้อความถูกส่งตรงแล้วทิ้ง ไม่ลง DB; โรงเรียนใหญ่ควรใช้ on-premise model แทน API ภายนอก
Accountability	Human-in-the-loop บังคับ: AI เป็น "ผู้ช่วย" ไม่ใช่ "ผู้ตัดสิน" + Audit log ทุกการแก้คะแนนพร้อมเหตุผล	ทำแล้วในแอป — Teacher Override บังคับกรอกเหตุผล มิฉะนั้นบันทึกไม่ได้
Consistency	temperature ต่ำ + ตรวจหลายรอบใช้มัธยฐาน + แจ้งผู้ใช้ตรง ๆ ว่าระบบมีความแปรปรวนเท่าไร	ทำแล้วในแอป — Consistency Check ×3 แสดงส่วนต่างพร้อมคำแนะนำ

05 เราใช้ Vibe Coding สร้างแอปอย่างไร (ลำดับ prompt จริง — แอปนี้ถูก vibe code ทั้งโปรเจกต์)

ลำดับการทำงาน

- **1. ป้อนโจทย์** — ส่ง PDF ใบงาน + ไอเดียที่เลือกให้ AI agent (Hermes Agent + Qwen 3.8 Max)
- **2. ให้ agent วางแผน** — เสนอสถาปัตยกรรม: static web app + local proxy (Python stdlib) + Demo Mode
- **3. Agent เขียนโค้ดทั้งโปรเจกต์** — HTML / CSS / JS 3 ไฟล์ / serve.py โดยเรา **ไม่ได้พิมพ์โค้ดเองเลย**
- **4. Agent ทดสอบตัวเอง** — เรียก API จริง + ขับเบราว์เซอร์ headless (CDP) กดทุก flow + ตรวจ screenshot ว่าภาษาไทย render ถูก
- **5. เจอบั๊กจริง → แก้** — โมเดล reasoning เผา token budget กับการ "คิด" จนได้คำตอบว่างเปล่า → เพิ่ม max_tokens + auto-retry
- **6. Deploy** — git push → GitHub Pages อัตโนมัติ

เครื่องมือ

Hermes Agent · Qwen 3.8 Max · Vanilla HTML/CSS/JS · Python stdlib proxy · GitHub Pages

Prompt หลักที่มนุษย์พิมพ์จริง

```
"i need to made an app for this i think web app
 would work what you think"

"can you plan it out and do the whole thing for me"
```

ที่เหลือ agent ต่อยอดเองทั้งหมด: ออกแบบ UI, เขียน prompt engineering ของระบบตรวจ (rubric prompt, JSON schema, evidence rule), ทดสอบ, แก้บั๊ก, deploy

ผลลัพธ์

เว็บแอปทำงานได้จริงครบทุก flow ภายใน**เซสชันเดียว** — ถ้าเขียนเองตามวิธีดั้งเดิม (ออกแบบ UI, เขียน backend, ทดสอบ, deploy) อาจใช้เวลาหลายวัน

สิ่งที่มนุษย์ยังต้องทำ

- ตัดสินใจเลือกไอเดียและยืนยันสถาปัตยกรรม
- ตรวจสอบว่าผลตรวจของ AI สมเหตุสมผล (อ่าน evidence ด้วยตา)
- รับผิดชอบต่อสิ่งที่ deploy ออกสู่สาธารณะ

→ แก่นของ vibe coding: มนุษย์ย้ายจาก "คนเขียนโค้ด" เป็น **"คนกำกับและรับผิดชอบ"**

06 Vibe Coding ก่อให้เกิดประเด็นจริยธรรมในการพัฒนาโปรแกรมอย่างไร (จาก

ประสบการณ์ตรงของโปรเจกต์นี้)

1 · นักพัฒนาไม่เข้าใจโค้ดที่ตนปล่อยออกไป

โค้ดถูกสร้างเร็วเกินกว่าจะ review ทัน — เรา**ไม่เคยอ่าน serve.py ทั้งไฟล์**ก่อน deploy ถ้ามีช่องโหว่ (เช่น key รั่ว, injection) ผู้ใช้จริงคือเหยื่อ ทั้งที่ไม่มีใครตั้งใจเขียนบั๊ก → คำถาม accountability: **ใครรับผิดชอบโค้ดที่มนุษย์สั่งให้เกิดแต่ไม่เคยอ่าน?**

2 · ความปลอดภัยถูกแลกกับความไว

ตัวอย่างจริงจากโปรเจกต์: agent เผลอ commit ไฟล์ log เข้า git repo สาธารณะรอบแรก (ไม่มี key แต่สะท้อนว่า **vibe coding ทำให้ "พลาดแล้วเผยแพร่" เกิดง่ายมาก** เพราะทุกอย่างเร็วและอัตโนมัติ) — ถ้าพลาดเป็นไฟล์ key.txt ผลคือ key รั่วสู่สาธารณะทันที

3 · อคติของโมเดลถูกฝังลงในผลิตภัณฑ์โดยไม่รู้ตัว

AI เขียนทั้ง UI copy, rubric, prompt วิศวกรรม — **ค่านิยมที่แฝงในข้อมูลฝึกของโมเดลถูกส่งต่อให้ผู้ใช้ปลายทางโดยไม่มีใครกรอง** เช่น การเลือกเกณฑ์ให้คะแนนแบบไหน "ดี" ก็ถูกตัดสินโดยโมเดลตั้งแต่ต้น

4 · ทักษะนักพัฒนารุ่นใหม่ถูกกัดกร่อน

ถ้าเด็ก CS พึ่ง vibe coding ตั้งแต่เรียนปี 1 จะ**ไม่ผ่านการฝึก debug/ออกแบบด้วยตัวเอง** — ระยะยาวอุตสาหกรรมได้ "ผู้กดปุ่ม" ที่แยกแยะโค้ดดี/เลวไม่ได้ ซึ่งเป็นอันตรายเมื่อระบบที่ต้องรับผิดชอบมีผลกระทบต่อชีวิตคน

5 · ผลงาน/ลิขสิทธิ์กำกวม

โค้ดที่โมเดลเขียนอาจ**คล้ายโค้ดมีลิขสิทธิ์จากข้อมูลฝึก** โดยไม่มีใครรู้ — ใครเป็นเจ้าของแอปนี้? คนสั่ง? บริษัทโมเดล? และถ้าแอปทำรายได้ ลิขสิทธิ์อยู่ที่ใคร (ปัจจุบันกฎหมายยังไม่มีคำตอบชัด)

แนวทางของเรา: Vibe Coding อย่างรับผิดชอบ

- ใช้ agent เขียน แต่**ทดสอบทุก flow ด้วยตัวเอง/ด้วยเครื่องมืออัตโนมัติ**ก่อนส่งมอบ
- ความลับ (API key) ต้องอยู่นอกโค้ดที่ commit เสมอ + ตรวจ git ก่อน push
- เปิดเผยในสไลด์ตรง ๆ ว่าส่วนไหน AI ทำ ส่วนไหนมนุษย์ตัดสินใจ

07 แหล่งอ้างอิง

- Office of the United Nations High Commissioner for Human Rights. (2024). *Artificial intelligence and human rights.* https://www.ohchr.org/en/digital-age/artificial-intelligence-and-human-rights
- European Union. (2024). *Artificial Intelligence Act (Regulation (EU) 2024/1689).* https://artificialintelligenceact.eu
- UNESCO. (2021). *Recommendation on the Ethics of Artificial Intelligence.* https://unesdoc.unesco.org/ark:/48223/pf0000381137
- สำนักงานคณะกรรมการคุ้มครองข้อมูลส่วนบุคคล. (2565). *พระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล พ.ศ. 2562 (PDPA).* https://www.pdpc.or.th
- Karpathy, A. (2025, February 3). *"There's a new kind of coding I call 'vibe coding'"* [Post]. X. https://x.com/karpathy/status/1886192184808149383
- OpenAI. (n.d.). *GPT-4 system card.* https://cdn.openai.com/papers/gpt-4-system-card.pdf
- Lecturer, KMITL. (2569). *ใบงาน Term Project: เรื่อง Ethics in AI — วิชา 05506015 Computer Ethics and Professional Issues.* (เอกสารประกอบการเรียน)

08 สมาชิกกลุ่ม

กลุ่ม Dario Amodei · จำนวนสมาชิก **6** คน

1.	69050510	วัชระ จันนามอม	(เพชร)
2.	69050737	จิตตวดี สุเดชะ	(บีม)
3.	69050778	ชุติเทพ แสงเดือน	(ปาล์ม)
4.	69050784	ฐนกร โสมาบุตร	(เก่ง)
5.	69051095	วสุพล พิรุณรักษ์	(โอม)
6.	69051119	ศิริขวัญ บุญประสาร	(โมริ)

Sec วันพุธ · วิชา 05506015 Computer Ethics and Professional Issues · ภาคเรียน 1/2569