🎬 Demo Runbook — AI Essay & Quiz Grader

กลุ่ม Dario Amodei · นำเสนอ Sec วันพุธ · เตรียมก่อนนำเสนอ 15 นาที

สรุปสิ่งที่ต้องทำวันนำเสนอ (3 ขั้นตอน):

1. เปิด Terminal → `cd ~/Projects/ai-essay-grader` → `python3 serve.py` (ห้ามปิดหน้าต่างนี้)
2. เปิดเบราว์เซอร์ → `http://localhost:8000` → มุมขวาบนต้องขึ้นป้ายเขียว **"LIVE · AI ทำงานจริง"**
3. ทำตามคิวการสาธิตด้านล่าง — ทุกอย่างมีปุ่มสำเร็จรูป ไม่ต้องพิมพ์เองเลย

⛔ **ห้ามทำ / ข้อควรระวัง:**

- **ห้าม demo จากลิงก์ GitHub Pages** — เวอร์ชันนั้นเป็น Demo Mode (ไม่มี proxy) ป้ายจะขึ้นสีเหลือง "DEMO" ถ้าขึ้นแบบนั้นแสดงว่าเปิดผิด URL
- **ห้ามปิด Terminal ที่รัน serve.py** ระหว่างนำเสนอ — ปิดเมื่อไหร่ แอปตายทันที
- **ห้ามแชร์/โพสต์ไฟล์** `key.txt` หรือแคปหน้าจอที่เห็นเนื้อหาไฟล์นี้
- ถ้าอินเทอร์เน็ตห้องเรียนล่ม → แอปจะ error ชัดเจน ไม่ต้องโกหกว่า live: สลับไปเล่า Demo Mode ได้ (ป้ายเหลือง) หรือเปิดวิดีโอ/สกรีนช็อตสำรอง
- AI ตอบไม่เหมือนกันทุกรอบ — คะแนนอาจต่างจากในเอกสารนี้ **เป็นเรื่องปกติ และเป็นจุดขาย** (พูดตามสคริปต์ข้อ 4)

📋 คิวการสาธิต (ประมาณ 5–7 นาที)

#	ทำอะไร (กดอะไร)	สิ่งที่คนดูจะเห็น + สคริปต์พูด
1	แท็บ **ตรวจเรียงความ** → กดปุ่ม 🇹🇭 เรียงความไทย (คุณภาพดี) → กด ✨ **ตรวจและให้คะแนน**	รอ ~15–40 วินาที (มี spinner) → คะแนนรวม + รายเกณฑ์ 4 ด้าน ทุกเกณฑ์มีคอมเมนต์ภาษาไทย และ **กล่อง "หลักฐานจากตัวงาน (Anti-Hallucination)"** ที่ quote ข้อความจริงจากเรียงความ > *"สังเกตว่าทุกคะแนน AI ต้องยกข้อความจริงจากงานนักเรียนมาเป็นหลักฐาน — นี่คือกลไกกัน AI มโนที่เราฝังไว้ในระบบ"*
2	เปิด 🔍 **Transparency — ดูคำสั่ง (prompt) ที่จะส่งให้ AI**	เห็น prompt จริงทั้งก้อน รวมถึงกฎ anti-bias ที่เขียนกำกับ AI ไว้ > *"ผู้ใช้ดูได้ว่า AI ถูกสั่งอะไร และตัดสินจากเกณฑ์ไหน — ไม่มี black box"*
3	กด 🇬🇧 English essay (strong) → ตรวจ → จดคะแนน → แล้วกด 🌍 non-native writer — bias test → ตรวจอีกครั้ง	**ไฮไลต์ของงาน!** ผลทดสอบจริงที่เราวัดได้: strong ได้ **36/40** vs non-native ได้ **26/40** ทั้งที่เนื้อหาและเหตุผลลึกพอ ๆ กัน ต่างแค่ความลื่นไหลของภาษา > *"สองงานนี้เราจงใจเขียนให้เนื้อหาดีเท่ากัน แต่ชิ้นหนึ่งเขียนโดยจำลองสไตล์ non-native — ผลต่าง 10 คะแนนเต็มคือหลักฐานว่า Bias & Fairness ไม่ใช่ทฤษฎีลอย ๆ แต่เกิดขึ้นจริงกับระบบแบบนี้ และนี่คือเหตุผลที่ต้องมีมนุษย์ทบทวนคะแนนเสมอ"*
4	กด 🔁 **Consistency Check (×3)**	ระบบตรวจงานเดิม 3 รอบ → ตารางเทียบคะแนนรายเกณฑ์รายรอบ พร้อมส่วนต่าง (รอบทดสอบจริงเราได้ 34→34→30 = **แกว่ง 4 คะแนน**)

		> *"งานเดิม คนเดิม ตรวจ 3 ครั้ง คะแนนไม่เท่ากัน — นี่คือปัญหา Reliability ที่ผู้ใช้อาจไม่รู้ตัว ถ้าเราไม่โชว์ให้ดูตรง ๆ"*
5	ตรงช่อง **สิทธิ์ครู (Human Oversight)** → แก้คะแนน → ใส่เหตุผล → กด ✍️ **บันทึก** → เปิดแท็บ **Audit Log**	เห็นบันทึก: เวลา · คะแนน AI → คะแนนที่มนุษย์แก้ · เหตุผล (ถ้าไม่ใส่เหตุผล ระบบ**ไม่ยอมให้บันทึก** — ลองให้ดูได้) > *"ครูแก้คะแนนได้เสมอ แต่ต้องรับผิดชอบเป็นลายลักษณ์อักษร — AI เป็นผู้ช่วย ไม่ใช่ผู้ตัดสิน"*
6	แท็บ **ตรวจข้อสอบปรนัย** → กด 📄 ชุดที่ 2 (จริยธรรม AI) → กด ✨ **สร้างเฉลยและตรวจคำตอบ**	AI สร้างเฉลย 4 ข้อพร้อมคำอธิบายรายข้อ → เทียบคำตอบนักเรียน (ชุดนี้จงใจตอบผิด 1 ข้อ) → เห็น ✓/✗ รายข้อ + คะแนน 3/4 > *"โจทย์ชุดนี้คือข้อสอบจริยธรรม AI เอง — ให้ AI เฉลยข้อสอบที่ถามเรื่องจริยธรรมของมันเอง เป็นการปิดท้ายที่ชวนคิดดีครับ/ค่ะ"*
7	กด 🔒 **ความเป็นส่วนตัว** (มุมขวาบน)	แสดงนโยบาย: ไม่เก็บงานนักเรียน · key อยู่ฝั่ง proxy ไม่ผ่านเบราว์เซอร์ · audit log อยู่ในเครื่อง > *"Privacy by design — และเราระบุข้อจำกัดตรง ๆ ว่าถ้าส่งงานไป API ภายนอก ข้อมูลยังอยู่ใต้นโยบายผู้ให้บริการ โรงเรียนที่ต้องการเข้มงวดควรใช้ on-premise model"*

💡 **ถ้าเวลาเหลือ:** กด 💼 Pitch Deck เพื่อโชว์ว่าสลับ rubric ได้ (ตรวจข้อเสนอธุรกิจ EduFair) · หรือกด 🇹🇭 ควรปรับปรุง เพื่อโชว์ว่างานคุณภาพต่ำได้คะแนนต่ำจริง (ระบบไม่ได้ใจดีกับทุกงาน)

🆘 แผนสำรองเมื่อมีปัญหา (Troubleshooting)

อาการ	สาเหตุ + วิธีแก้
ป้ายมุมขวาขึ้น **"DEMO MODE"** ทั้งที่เปิด localhost	serve.py ไม่ได้รัน หรือรันโดยไม่เห็น key → เปิด Terminal ใหม่: `cd ~/Projects/ai-essay-grader && python3 serve.py` แล้ว**รีเฟรชหน้าเว็บ** — ป้ายต้องเปลี่ยนเป็นเขียว LIVE (Demo Mode ก็ยังนำเสนอได้ แต่ต้องบอกตรง ๆ ว่าเป็นผลจำลอง)
กดตรวจแล้วขึ้น ❌ error	ส่วนใหญ่คือเน็ตหลุด/ช้า หรือ API ตอบว่าง → กดปุ่มตรวจซ้ำได้เลย (ระบบมี auto-retry 1 ครั้งอยู่แล้ว) ถ้ายังไม่หาย รอ 10 วิแล้วลองใหม่
รอนานผิดปกติ (> 1 นาที)	โมเดลเป็น reasoning model ใช้เวลา "คิด" ก่อนตอบ → ระหว่างรอให้พูดอธิบาย spinner / เปิด Transparency panel ฆ่าเวลา — ไม่ต้องนิ่งเงียบ
Port 8000 ถูกใช้	`PORT=8080 python3 serve.py` แล้วเปิด `http://localhost:8080`
อินเทอร์เน็ตห้องใช้ไม่ได้เลย	เปิดสกรีนช็อต/คลิปที่เตรียมไว้ หรือสลับไป Demo Mode แล้วพูดตรง ๆ ว่า "โหมดจำลองมีไว้สำหรับสถานการณ์แบบนี้ — สังเกตว่าแอปติดป้าย DEMO ชัดเจน ไม่หลอกผู้ใช้ว่าผลเป็น AI จริง" (เปลี่ยนจุดอ่อนเป็นตัวอย่างความโปร่งใสได้!)

✅ Checklist ก่อนออกจากหอพัก

- ☐ โน้ตบุ๊กชาร์จเต็ม + สายชาร์จติดกระเป๋า (ห้าม demo บนแบตเตอรี่ 20%)
- ☐ ต่อเน็ตมือถือ (hotspot) สำรองไว้ — อย่าพึ่ง Wi-Fi ห้องเรียนอย่างเดียว
- ☐ เปิดแท็บเบราว์เซอร์ค้างไว้ 2 แท็บ: แอป + สไลด์ PDF
- ☐ ปิด notification ทุกอย่าง (Do Not Disturb) ก่อนขึ้นนำเสนอ
- ☐ ซ้อมคิว 1 รอบเต็มจับเวลา (เป้า: 5–7 นาที)
- ☐ ส่งไฟล์ `DarioAmodei-EthicsInAI-Wed.pdf` เข้า Classroom **ก่อน 13.00 น.** วันนำเสนอ

🎤 คำถามที่อาจารย์อาจถาม + แนวคำตอบ

- **"คะแนนเชื่อถือได้แค่ไหน?"** → ตอบตรง ๆ: ไม่น่าเชื่อถือพอให้ตัดสินมนุษย์เดี่ยว ๆ — นั่นคือเหตุผลที่เราทำ Consistency Check ให้เห็นกับตา และบังคับ Teacher Override พร้อม audit log
- **"ใครรับผิดชอบถ้า AI ให้คะแนนผิด?"** → ตามดีไซน์ของเรา: ครูผู้ยืนยันผลเป็นคนรับผิดชอบ (human-in-the-loop) โดยมี audit trail ย้อนดูได้ — และเรายอมรับว่าในกฎหมายปัจจุบันยังไม่มีคำตอบระดับอุตสาหกรรมที่ชัด
- **"ข้อมูลนักเรียนไปไหน?"** → ไม่ถูกเก็บฝั่งเรา (stateless) แต่ถูกส่งไปผู้ให้บริการโมเดลตาม prompt ที่แสดงโปร่งใสใน Transparency panel — ถ้าเป็นข้อมูลอ่อนไหวของเยาวชนจริง ควร anonymize ก่อน หรือใช้ on-premise model
- **"vibe coding ทั้งโปรเจกต์แบบนี้ นักศึกษาได้อะไร?"** → เราไม่ได้เขียนโค้ดเอง แต่เรา**กำกับ ตรวจสอบ และรับผิดชอบ**: กำหนดสถาปัตยกรรม, เทียบผล AI กับ expectation, เจอบั๊กจริง (reasoning model ตอบว่าง) และตัดสินใจเชิงจริยธรรมทุกอย่างที่ฝังในแอป — สไลด์หน้า 6 เล่าตรง ๆ ว่าความเสี่ยงคืออะไร

ผลทดสอบจริงทั้งหมดในเอกสารนี้ (36 vs 26 คะแนน bias test, 34→34→30 consistency) มาจากการรันแอปกับ Qwen 3.8 Max จริงเมื่อวันที่ 27 ต.ค. 2569 — คะแนนวันนำเสนอจริงอาจต่างไปเล็กน้อย ซึ่ง**คาดได้และอธิบายได้**