🎬 Demo Runbook — AI Essay & Quiz Grader

กลุ่ม Dario Amodei · นำเสนอ Sec วันพุธ · เตรียมก่อนนำเสนอ 15 นาที

สรุปสิ่งที่ต้องทำวันนำเสนอ (3 ขั้นตอน):

1. เปิด Terminal → `cd ~/Projects/ai-essay-grader` → `python3 serve.py` (ห้ามปิดหน้าต่างนี้)
2. เปิดเบราว์เซอร์ → `http://localhost:8000` → มุมขวาบนต้องขึ้นป้ายเขียว **"LIVE · AI ทำงานจริง"**
3. ทำตามคิวการสาธิตด้านล่าง — ทุกอย่างมีปุ่มสำเร็จรูป ไม่ต้องพิมพ์เองเลย

⛔ **ห้ามทำ / ข้อควรระวัง:**

- **ห้าม demo จากลิงก์ GitHub Pages** — เวอร์ชันนั้นเป็น Demo Mode (ไม่มี proxy) ป้ายจะขึ้นสีเหลือง "DEMO" ถ้าขึ้นแบบนั้นแสดงว่าเปิดผิด URL
- **ห้ามปิด Terminal ที่รัน serve.py** ระหว่างนำเสนอ — ปิดเมื่อไหร่ แอปตายทันที
- **ห้ามแชร์/โพสต์ไฟล์** `key.txt` หรือแคปหน้าจอที่เห็นเนื้อหาไฟล์นี้
- ถ้าอินเทอร์เน็ตห้องเรียนล่ม → แอปจะ error ชัดเจน ไม่ต้องโกหกว่า live: สลับไปเล่า Demo Mode ได้ (ป้ายเหลือง) หรือเปิดวิดีโอ/สกรีนช็อตสำรอง
- AI ตอบไม่เหมือนกันทุกรอบ — คะแนนอาจต่างจากในเอกสารนี้ **เป็นเรื่องปกติ และเป็นจุดขาย** (พูดตามสคริปต์ข้อ 4)

⏱️ เวลาจริงของแต่ละขั้น (วัดจากเครื่องจริง 27 ต.ค. 2569 — โมเดล GPT-OSS 120B)

ขั้น	เวลาเฉลี่ยที่วัดได้	หมายเหตุ
ตรวจเรียงความ 1 ชิ้น	**6–15 วินาที**	บนจอมีตัวจับเวลาเดินให้คนดูไม่เบื่อ
Consistency Check ×3 (รันขนาน)	**~15–20 วินาที**	เคยใช้เวลา 4+ นาทีตอนรันทีละรอบ — เราแก้ให้รัน 3 รอบพร้อมกันแล้ว
ตรวจข้อสอบปรนัย	**~3–5 วินาที**	เร็วสุดในเดโม — ใช้เป็นขั้นปิดถ้าเวลาหมด
ทั้งเดโม (คิว 7 ขั้น)	**~5–7 นาที**	รวมเวลาพูดด้วย เหลือ buffer จากกรอบนำเสนอ

⚠️ ตัวเลขนี้วัดด้วยโมเดล **GPT-OSS 120B** (ค่า default ใหม่ใน Settings) — ถ้าสลับไปใช้ Qwen 3.8 Max จะช้าลงมาก (40–290 วินาทีต่อครั้ง) **ห้ามสลับโมเดลวันนำเสนอ**

📋 คิวการสาธิต (ประมาณ 5–7 นาที)

#	ทำอะไร (กดอะไร)	สิ่งที่คนดูจะเห็น + สคริปต์พูด
1	แท็บ **ตรวจเรียงความ** → กดปุ่ม 🇹🇭 เรียงความไทย (คุณภาพดี) → กด ✨ **ตรวจและให้คะแนน**	รอ **~6–15 วินาที** (มี spinner + ตัวจับเวลาเดินบนจอ) → คะแนนรวม + รายเกณฑ์ 4 ด้าน ทุกเกณฑ์มีคอมเมนต์ภาษาไทย และ **กล่อง "หลักฐานจากตัวงาน (Anti-Hallucination)"** ที่ quote ข้อความจริงจากเรียงความ > *"สังเกตว่าทุกคะแนน AI ต้องยกข้อความจริงจากงานนักเรียนมาเป็นหลักฐาน — นี่คือกลไกกัน AI มโนที่เราฝังไว้ในระบบ"*

2	เปิด 🔍 **Transparency — ดูคำสั่ง (prompt) ที่จะส่งให้ AI**	เห็น prompt จริงทั้งก้อน รวมถึงกฎ anti-bias ที่เขียนกำกับ AI ไว้ *"ผู้ใช้ดูได้ว่า AI ถูกสั่งอะไร และตัดสินจากเกณฑ์ไหน — ไม่มี black box"*
3	กด 🇬🇧 English essay (strong) → ตรวจ → จดคะแนน → แล้วกด 🌍 non-native writer — bias test → ตรวจอีกครั้ง	**ไฮไลต์ของงาน!** ผลทดสอบจริงที่เราวัดได้: strong ได้ **~34–36/40** vs non-native ได้ **~22–26/40** ทั้งที่เนื้อหาและเหตุผลลึกพอ ๆ กัน ต่างแค่ความลื่นไหลของภาษา (ตัวเลขจริง ณ วันทดสอบล่าสุด: 34 vs 22 — ห่าง 12 คะแนน) *"สองงานนี้เราจงใจเขียนให้เนื้อหาดีเท่ากัน แต่ชิ้นหนึ่งเขียนโดยจำลองสไตล์ non-native — ผลต่าง 10+ คะแนนคือหลักฐานว่า Bias & Fairness ไม่ใช่ทฤษฎีลอย ๆ แต่เกิดขึ้นจริงกับระบบแบบนี้ และนี่คือเหตุผลที่ต้องมีมนุษย์ทบทวนคะแนนเสมอ"*
4	กด 🔁 **Consistency Check (×3)**	ระบบตรวจงานเดิม 3 รอบ**พร้อมกัน** (~15–20 วินาที) → ตารางเทียบคะแนนรายเกณฑ์รายรอบ พร้อมส่วนต่าง (รอบทดสอบจริงเราได้ 32→34→34 = **แกว่ง 2 คะแนน** และเคยวัดได้ถึง 4 คะแนน) *"งานเดิม คนเดิม ตรวจ 3 ครั้ง คะแนนไม่เท่ากัน — นี่คือปัญหา Reliability ที่ผู้ใช้อาจไม่รู้ตัว ถ้าเราไม่โชว์ให้ดูตรง ๆ"*
5	ตรงช่อง **สิทธิ์ครู (Human Oversight)** → แก้คะแนน → ใส่เหตุผล → กด ✍️ **บันทึก** → เปิดแท็บ **Audit Log**	เห็นบันทึก: เวลา · คะแนน AI → คะแนนที่มนุษย์แก้ · เหตุผล (ถ้าไม่ใส่เหตุผล ระบบ**ไม่ยอมให้บันทึก** — ลองให้ดูได้) *"ครูแก้คะแนนได้เสมอ แต่ต้องรับผิดชอบเป็นลายลักษณ์อักษร — AI เป็นผู้ช่วย ไม่ใช่ผู้ตัดสิน"*
6	แท็บ **ตรวจข้อสอบปรนัย** → กด 📄 ชุดที่ 2 (จริยธรรม AI) → กด ✨ **สร้างเฉลยและตรวจคำตอบ**	AI สร้างเฉลย 4 ข้อพร้อมคำอธิบายรายข้อ → เทียบคำตอบนักเรียน (ชุดนี้จงใจตอบผิด 1 ข้อ) → เห็น ✓/✗ รายข้อ + คะแนน 3/4 *"โจทย์ชุดนี้คือข้อสอบจริยธรรม AI เอง — ให้ AI เฉลยข้อสอบที่ถามเรื่องจริยธรรมของมันเอง เป็นการปิดท้ายที่ชวนคิดดีครับ/ค่ะ"*
7	กด 🔒 **ความเป็นส่วนตัว** (มุมขวาบน)	แสดงนโยบาย: ไม่เก็บงานนักเรียน · key อยู่ฝั่ง proxy ไม่ผ่านเบราว์เซอร์ · audit log อยู่ในเครื่อง *"Privacy by design — และเราระบุข้อจำกัดตรง ๆ ว่าถ้าส่งงานไป API ภายนอก ข้อมูลยังอยู่ใต้นโยบายผู้ให้บริการ โรงเรียนที่ต้องการเข้มงวดควรใช้ on-premise model"*

💡 **ถ้าเวลาเหลือ:** กด 💼 Pitch Deck เพื่อโชว์ว่าสลับ rubric ได้ (ตรวจข้อเสนอธุรกิจ EduFair) · หรือกด 🇹🇭 ควรปรับปรุง เพื่อโชว์ว่างานคุณภาพต่ำได้คะแนนต่ำจริง (ระบบไม่ได้ใจดีกับทุกงาน)

🆘 แผนสำรองเมื่อมีปัญหา (Troubleshooting)

อาการ	สาเหตุ + วิธีแก้
ป้ายมุมขวาขึ้น **"DEMO MODE"** ทั้งที่เปิด localhost	serve.py ไม่ได้รัน หรือรันโดยไม่เห็น key → เปิด Terminal ใหม่: `cd ~/Projects/ai-essay-grader && python3 serve.py` แล้ว**รีเฟรชหน้าเว็บ** — ป้ายต้องเปลี่ยนเป็นเขียว LIVE (Demo Mode ก็ยังนำเสนอได้ แต่ต้องบอกตรง ๆ ว่าเป็นผลจำลอง)
กดตรวจแล้วขึ้น ❌ error	ส่วนใหญ่คือเน็ตหลุด/ช้า หรือ API ตอบว่าง → กดปุ่มตรวจซ้ำได้เลย (ระบบมี auto-retry 1 ครั้งอยู่แล้ว) ถ้ายังไม่หาย รอ 10 วิแล้วลองใหม่
รอนานผิดปกติ (> 30 วินาที)	เน็ตช้าหรือ gateway คิวเยอะ → ตัวจับเวลาบนจอยังเดินอยู่ ให้พูดอธิบาย Transparency panel ฆ่าเวลา · ถ้าเกิน ~60 วิ กดปุ่มตรวจใหม่ได้เลย · **ตรวจว่า Settings ยังเป็นโมเดล GPT-OSS 120B** (ถ้าเผลอเลือก Qwen 3.8 Max จะช้า 40–290 วิ/ครั้ง)
Port 8000 ถูกใช้ (Errno 48)	ปกติจะมี serve.py ค้างอยู่ → รันซ้ำได้เลย ตัวใหม่จะ**เลื่อนไป port 8001 อัตโนมัติ** (ดู URL ที่พิมพ์ใน Terminal) — หรือปิดตัวเก่า: `pkill -f serve.py` แล้วรันใหม่
อินเทอร์เน็ตห้องใช้ไม่ได้เลย	เปิดสกรีนช็อต/คลิปที่เตรียมไว้ หรือสลับไป Demo Mode แล้วพูดตรง ๆ ว่า "โหมดจำลองมีไว้สำหรับสถานการณ์แบบนี้ — สังเกตว่าแอปติดป้าย DEMO ชัดเจน ไม่หลอกผู้ใช้ว่าผลเป็น AI จริง" (เปลี่ยนจุดอ่อนเป็นตัวอย่างความโปร่งใสได้!)

✅ Checklist ก่อนออกจากหอพัก

- □ โน้ตบุ๊กชาร์จเต็ม + สายชาร์จติดกระเป๋า (ห้าม demo บนแบตเตอรี่ 20%)
- □ ต่อเน็ตมือถือ (hotspot) สำรองไว้ — อย่าพึ่ง Wi-Fi ห้องเรียนอย่างเดียว
- □ เปิดแท็บเบราว์เซอร์ค้างไว้ 2 แท็บ: แอป + สไลด์ PDF
- □ ปิด notification ทุกอย่าง (Do Not Disturb) ก่อนขึ้นนำเสนอ
- □ ซ้อมคิว 1 รอบเต็มจับเวลา (เป้า: 5–7 นาที)
- □ ส่งไฟล์ `DarioAmodei-EthicsInAI-Wed.pdf` เข้า Classroom **ก่อน 13.00 น.** วันนำเสนอ

🎤 คำถามที่อาจารย์อาจถาม + แนวคำตอบ

- **"คะแนนเชื่อถือได้แค่ไหน?"** → ตอบตรง ๆ: ไม่น่าเชื่อถือพอให้ตัดสินมนุษย์เดี่ยว ๆ — นั่นคือเหตุผลที่เราทำ Consistency Check ให้เห็นกับตา และบังคับ Teacher Override พร้อม audit log
- **"ใครรับผิดชอบถ้า AI ให้คะแนนผิด?"** → ตามดีไซน์ของเรา: ครูผู้ยืนยันผลเป็นคนรับผิดชอบ (human-in-the-loop) โดยมี audit trail ย้อนดูได้ — และเรายอมรับว่าในกฎหมายปัจจุบันยังไม่มีคำตอบระดับอุตสาหกรรมที่ชัด
- **"ข้อมูลนักเรียนไปไหน?"** → ไม่ถูกเก็บฝั่งเรา (stateless) แต่ถูกส่งไปผู้ให้บริการโมเดลตาม prompt ที่แสดงโปร่งใสใน Transparency panel — ถ้าเป็นข้อมูลอ่อนไหวของเยาวชนจริง ควร anonymize ก่อน หรือใช้ on-premise model
- **"vibe coding ทั้งโปรเจกต์แบบนี้ นักศึกษาได้อะไร?"** → เราไม่ได้เขียนโค้ดเอง แต่เรา**กำกับ ตรวจสอบ และรับผิดชอบ**: กำหนดสถาปัตยกรรม, เทียบผล AI กับ expectation, เจอบั๊กจริง (reasoning model ตอบว่าง) และตัดสินใจเชิงจริยธรรมทุกอย่างที่ฝังในแอป — สไลด์หน้า 6 เล่าตรง ๆ ว่าความเสี่ยงคืออะไร

ผลทดสอบจริงทั้งหมดในเอกสารนี้ (36 vs 26 คะแนน bias test, 34→34→30 consistency) มาจากการรันแอปกับ Qwen 3.8 Max จริงเมื่อวันที่ 27 ต.ค. 2569 — คะแนนวันนำเสนอจริงอาจต่างไปเล็กน้อย ซึ่ง**คาดได้และอธิบายได้**